

PRACTICA 1

Joaquin Emmanuel Aldair
Coromac Huevo
201903873

Guatemala, 27 de Febrero de 2026

ETL con Python: de dataset crudo a tabla relacional lista para análisis

Las organizaciones actuales generan grandes volúmenes de información provenientes de diversas fuentes. Para aprovechar estos datos de forma estratégica, se requiere implementar un proceso de integración y análisis estructurado. En esta práctica, el estudiante deberá diseñar e implementar un proceso ETL (Extracción, Transformación y Carga) utilizando Python y SQL Server. El escenario simula el manejo de información proveniente de registros de vuelos, donde los datos se encuentran en múltiples fuentes heterogéneas y deben ser estandarizados para su análisis. El objetivo es construir un modelo multidimensional de inteligencia de negocios que permita ejecutar consultas analíticas y generar información útil para la toma de decisiones.

Dataset 2 (Datos del Pasajero y Compra)

Nombre Original	Traducción	Descripción	Tipo de Dato Óptimo (SQL Server)
Passenger_id	ID de Pasajero	Identificador único del pasajero (formato UUID).	UNIQUEIDENTIFIER (Ocupa 16 bytes y está optimizado para UUIDs) o VARCHAR(36).

Passenger_gender	Género del Pasajero	Letra que representa el género (ej. M, F, X).	CHAR(1) (Como siempre es una letra, CHAR es más rápido que VARCHAR).
Passenger_age	Edad del Pasajero	Edad de años enteros (ej. 40).	TINYINT (Guarda números de 0 a 255. Perfecto para edades y ocupa solo 1 byte).
Passenger_nationality	Nacionalidad	Código de país de 2 letras (ej. PE, GT).	CHAR(2) (Siempre son 2 caracteres, muy ligero).
Booking_datetime	Fecha/Hora de Reserva	Momento exacto en que se compró el pasaje.	DATETIME2 o DATETIME (Recomiendo DATETIME2 porque es más preciso y estándar en SQL moderno).
Sales_channel	Canal de Venta	Plataforma donde compró (APP, CALL CENTER).	VARCHAR(20) (Texto variable corto).
Payment_method	Método de Pago	Forma en que pagó (EFECTIVO, TARJETA).	VARCHAR(20) (Texto variable corto).

Ticket_price	Precio del Boleto	Precio en moneda original. Ojo: Viene con comas (77,60).	Transformar en Python a: DECIMAL(10,2) (Para guardar 2 decimales exactos de moneda).
Currency	Moneda	Código de 3 letras de la divisa (USD, EUR, GTQ).	CHAR(3) (Siempre son 3 letras).
Ticket_price_usd_est	Precio Estimado USD	Equivalente del precio convertido a dólares.	DECIMAL(10,2) (Ideal para moneda en SQL Server).
Bags_total	Total Maletas	Cantidad total de equipaje (ej. 0, 1, 2).	TINYINT (Ocupa 1 byte, suficiente para contar maletas).
bags_checked	Maletas Facturadas	Maletas enviadas a la bodega del avión.	TINYINT (Ocupa 1 byte).

Dataset 1 (Datos del Vuelo)

Nombre Original	Traducción	Descripción	Tipo de Dato Óptimo (SQL Server)
Record_id	ID de Registro	Número correlativo único	INT (Números enteros estándar).

		del vuelo/registro.	
Airline_code	Código de Aerolínea	Código corto IATA (ej. FR, AV, DL).	VARCHAR(3) (Suelen ser de 2 o 3 caracteres).
Airline_name	Nombre de Aerolínea	Nombre comercial (ej. Ryanair, Avianca).	VARCHAR(100) (Texto variable).
Flight_number	Número de Vuelo	Identificador alfanumérico (ej. FR5515).	VARCHAR(10) (Texto corto).
Origin_airport	Aeropuerto Origen	Código IATA de 3 letras de salida (ej. MEX).	CHAR(3) (Siempre son 3 letras, más rápido que VARCHAR).
Destination_airport	Aeropuerto Destino	Código IATA de 3 letras de llegada (ej. GUA).	CHAR(3) (Siempre son 3 letras).
Departure_datetime	Fecha/Hora Salida	Momento exacto del despegue.	DATETIME2

Arrival_datetime	Fecha/Hora Llegada	Momento exacto del aterrizaje (puede ser nulo si se cancela).	DATETIME2 (Permitir NULL).
Duration_min	Duración (minutos)	Tiempo total de vuelo estimado.	SMALLINT (Guarda hasta 32,767. Mejor que INT para minutos).
Status	Estado del Vuelo	Situación actual (ON_TIME, CANCELLED).	VARCHAR(20) (Texto variable corto).
Delay_min	Retraso (minutos)	Minutos de retraso respecto a la salida.	SMALLINT (Permitir NULL si no aplica).
Aircraft_type	Tipo de Aeronave	Modelo del avión (ej. B739, A320).	VARCHAR(10) (Texto corto).
Cabin_class	Clase de Cabina	Categoría del pasaje (ECONOMY, BUSINESS).	VARCHAR(20) (Texto corto).
seat	Asiento	Posición en el avión (ej. 37F).	VARCHAR(5) (Letras y números cortos).

Descripción del Proceso ETL

El proceso ETL (Extract, Transform, Load) implementado en esta práctica integra dos fuentes de datos heterogéneas hacia un modelo multidimensional en SQL Server, habilitando consultas analíticas sobre registros de vuelos y pasajeros.

Fuentes de Datos

Se trabajó con dos archivos CSV de 10,000 registros cada uno, relacionados de forma posicional (misma cantidad de filas, unión por índice):

Archivo	Separador	Registros	Columnas	Contenido
Dataset_1.csv	Coma (,)	10,000	14	Datos del vuelo: aerolínea, aeropuerto, fechas, estado, aeronave, clase
Dataset_2.csv	Punto y coma (;)	10,000	12	Datos del pasajero: UUID, género, edad, nacionalidad, precio, canal de venta

Fase 1 — Extracción

Ambos archivos se leen con pandas, especificando encoding utf-8-sig para manejar el BOM (Byte Order Mark) presente en los archivos. Todos los campos se leen como texto (dtype=str) para preservar los valores tal como vienen y evitar conversiones automáticas incorrectas. Se verifica que ambos datasets tengan la misma cantidad de filas antes de continuar, ya que la relación entre ellos es posicional.

Fase 2 — Transformación

Esta fase resuelve todos los problemas de calidad identificados en los datos. La siguiente tabla documenta cada problema encontrado, su causa y la solución aplicada:

Problema	Dataset	Registros afectados	Solución aplicada
Códigos IATA en minúsculas	Dataset_1	779	Normalización con <code>.str.upper()</code>
Fechas en formato MM-DD-YYYY HH:MM AM/PM	Dataset_1 y 2	1,538	Función <code>parsear_fecha()</code> con 5 formatos
Fechas sin día con cero (ej: 4/10/2025)	Dataset_1 y 2	Variable	Incluido en <code>parsear_fecha()</code>

Vuelos cancelados sin llegada/duración/retraso	Dataset_1	560	Campos aceptados como NULL (esperado)
Precios con coma decimal (ej: 77,60)	Dataset_2	930	Reemplazo de ',' por '.' antes de float()
12 variantes de género	Dataset_2	1,317	Diccionario de normalización → M/F/X
Canal de venta vacío	Dataset_2	144	Asignación a 'DESCONOCIDO'
Edad = 0 (valor inválido)	Dataset_2	57	Conversión a NULL
Edad nula	Dataset_2	112	Se mantiene como NULL
Nacionalidad nula	Dataset_2	209	Se mantiene como NULL
Nombre de aerolínea con casing mixto	Dataset_1	Múltiple	Normalización al insertar en dimensión

Fase 3 — Carga

La carga se realiza en dos etapas: primero las tablas de dimensión y luego la tabla de hechos. Cada dimensión usa la cláusula IF NOT EXISTS antes de cada INSERT, lo que permite re-ejecutar el ETL sin generar duplicados. La tabla de hechos se inserta en bloque usando executemany() de pyodbc con fast_executemany=True para optimizar el rendimiento. Todo el proceso está envuelto en un bloque try/except con rollback automático ante cualquier error crítico. Adicionalmente, todos los eventos (filas procesadas, advertencias, errores) quedan registrados en un archivo etl_log.txt con timestamp.

Diseño del Modelo Multidimensional

El modelo sigue el esquema estrella (Star Schema) propuesto por Ralph Kimball, donde una tabla central de hechos se conecta directamente a tablas de dimensión desnormalizadas, optimizando la velocidad de las consultas analíticas.

Tabla de Hechos — Hechos_Vuelo

La granularidad del modelo es: un registro por cada vuelo-pasajero. Con 10,000 registros fuente, la tabla de hechos contiene hasta 10,000 filas (menos las omitidas por datos críticos faltantes).

Campo	Tipo	Descripción
ID_Fact	INT IDENTITY PK	Llave surrogate autoincremental
ID_Aerolinea	INT FK	DIM_AEROLINEA
ID_Pasajero	INT FK	DIM_PASAJERO
ID_Aeropuerto_Origen	INT FK	DIM_AEROPUERTO
ID_Aeropuerto_Destino	INT FK	DIM_AEROPUERTO (rol-playing)
ID_Fecha_Salida	INT FK NULL	DIM_TIEMPO (NULL si cancelado)
ID_Fecha_Llegada	INT FK NULL	DIM_TIEMPO (NULL si cancelado)
ID_Fecha_Reserva	INT FK	DIM_TIEMPO
ID_Canal	INT FK	DIM_CANAL
ID_Metodo	INT FK	DIM_METODO_PAGO
ID_Aeronave	INT FK	DIM_AERONAVE
ID_Clase	INT FK	DIM_CLASE
ID_Estado_Vuelo	INT FK	DIM_ESTADO_VUELO
Precio_Ticket	DECIMAL(10,2)	Precio en USD normalizado
Moneda_Original	CHAR(3)	Moneda de origen: USD, GTQ, EUR, MXN
Precio_Original	DECIMAL(10,2)	Precio en la moneda original
Total_Maletas	TINYINT	Total de maletas del pasajero
Maletas_Chequeadas	TINYINT	Maletas facturadas
Duracion	SMALLINT NULL	Duración del vuelo en minutos
Retraso	SMALLINT NULL	Minutos de retraso (NULL si no aplica)
Cantidad_Vuelo	TINYINT DEFAULT 1	Siempre 1, facilita agregaciones en BI

Tablas de Dimensión

DIM_TIEMPO

Generada dinámicamente por el ETL con todas las fechas únicas presentes en los datos (2024–2025). Su llave primaria es un entero en formato YYYYMMDD, eficiente para ordenamiento y rangos.

Campo	Tipo	Valores de ejemplo
ID_Fecha (PK)	INT	20240120, 20251215
Fecha_Completa	DATE	2024-01-20
Año	SMALLINT	2024, 2025
Mes	TINYINT	1 – 12
Nombre_Mes	VARCHAR(15)	Enero, Febrero...
Dia	TINYINT	1 – 31
Dia_Semana	TINYINT	1=Lunes ... 7=Domingo
Trimestre	TINYINT	1, 2, 3, 4
Es_Fin_Semana	BIT	0=Laboral, 1=Fin de semana

Nota: Rol-Playing Dimension

DIM_TIEMPO es referenciada tres veces desde Hechos_Vuelo mediante tres llaves foráneas distintas (ID_Fecha_Salida, ID_Fecha_Llegada, ID_Fecha_Reserva). En herramientas como Power BI esto se implementa creando tres vistas o copias de la dimensión con alias distintos (Fecha_Salida, Fecha_Llegada, Fecha_Reserva).

Dimensión	PK	Atributos	Valores reales del dataset
DIM_AEROLIN EA	ID_Aerolinea	Codigo, Nombre	12 aerolíneas: Ryanair, Avianca, Delta, LATAM, Copa Airlines, etc.
DIM_AEROPUE RTO	ID_Aeropuerto	Código, Nombre, Pais	15 aeropuertos IATA: GUA, MEX, JFK, MIA, BOG, LIM, BCN, MAD, etc.
DIM_PASAJER O	ID_Pasajero	Passenger_UU ID, Genero, Edad, Nacionalidad	10,000 pasajeros, 11 nacionalidades, géneros M/F/X

DIM_CANAL	ID_Canal	Canal	APP, AEROPUERTO, CALL_CENTER, WEB, AGENCIA, DESCONOCIDO
DIM_METODO_PAGO	ID_Metodo	Metodo_Pago	EFFECTIVO, TARJETA, TRANSFERENCIA, PAYPAL, PUNTOS
DIM_AERONAVE	ID_Aeronave	Tipo_Aeronave	12 tipos: B739, A320, B787, B777, CRJ9, E190, A321, etc.
DIM_CLASE	ID_Clase	Clase_Cabina	ECONOMY (78.7%), PREMIUM_ECONOMY, BUSINESS, FIRST
DIM_ESTADO_VUELO	ID_Estado_Vuelo	Estado	ON_TIME (72.8%), DELAYED (19.7%), CANCELLED (5.6%), DIVERTED (1.9%)

Pasos de Ejecución

Requisitos Tecnicos

Antes de ejecutar el ETL asegúrate de tener instalado:

- Python 3.10 o superior
- Microsoft SQL Server
- ODBC Driver 17 for SQL Server
- Las siguientes librerías de Python:

```
pip install pandas pyodbc sqlalchemy
```

Crear la base de datos y el modelo

Ejecuta el script SQL en SQL Server Management Studio (SSMS)

```
-- Abrir el archivo 01_crear_modelo.sql en SSMS
-- Ejecutar con F5 o botón 'Execute'
-- Verifica que se cree la base de datos VuelosBI con 10 tablas
```

Ejecutar el ETL

Desde la terminal, en la carpeta del proyecto:

```
python etl_vuelos.py
```

El proceso mostrará en consola el avance de cada fase. Un resultado exitoso luce así:

```
2026-02-24          10:00:01 [INFO]
=====
2026-02-24 10:00:01 [INFO] INICIO DEL PROCESO ETL - VuelosBI
2026-02-24          10:00:01 [INFO]
=====
2026-02-24 10:00:01 [INFO] FASE 1: EXTRACCIÓN
2026-02-24 10:00:02 [INFO] Dataset_1 leído: 10,000 filas, 14 columnas
2026-02-24 10:00:02 [INFO] Dataset_2 leído: 10,000 filas, 12 columnas
2026-02-24 10:00:02 [INFO] FASE 2: TRANSFORMACIÓN
2026-02-24 10:00:03 [WARNING] 779 aeropuertos en minúsculas → normalizados a mayúsculas
2026-02-24 10:00:03 [WARNING] 930 precios con coma decimal → corregidos
2026-02-24 10:00:03 [WARNING] 12 variantes de género → normalizadas a M/F/X
2026-02-24 10:00:03 [INFO] FASE 3: CARGA
2026-02-24 10:00:04 [INFO] DIM_TIEMPO: 730 registros cargados.
2026-02-24 10:00:04 [INFO] DIM_AEROLINEA: 12 registros.
2026-02-24 10:00:05 [INFO] Hechos_Vuelo: 10,000 registros insertados.
2026-02-24 10:00:05 [INFO] ETL COMPLETADO EXITOSAMENTE | Duración: 4 segundos
```

Validar y consultar

Abre el archivo 02_consultas_analiticas.sql en SSMS y ejecuta las consultas por sección para validar la carga y obtener los indicadores analíticos.

Resultados Obtenidos

Carga del Modelo

Tabla	Registros cargados	Observación
DIM_AEROLINEA	12	12 aerolíneas únicas normalizadas
DIM_AEROPUERTO	15	Enriquecidas con nombre y país
DIM_PASAJERO	10,000	UUIDs únicos
DIM_TIEMPO	730	Fechas únicas del rango 2024–2025
DIM_CANAL	6	Incluye DESCONOCIDO para vacíos
DIM_METODO_PAGO	5	Todos los métodos cubiertos
DIM_AERONAVE	12	Tipos IATA normalizados
DIM_CLASE	4	ECONOMY, PREMIUM_ECONOMY, BUSINESS, FIRST
DIM_ESTADO_VUELO	4	ON_TIME, DELAYED, CANCELLED, DIVERTED
Hechos_Vuelo	10,000	Un registro por vuelo-pasajero

Indicadores Analíticos

Distribución por estado de vuelo

Estado	Vuelos	Porcentaje
ON_TIME	7,278	72.78%
DELAYED	1,970	19.70%
CANCELLED	560	5.60%
DIVERTED	192	1.92%

Vuelos por clase de cabina

Clase	Vuelos	Porcentaje
ECONOMY	7,866	78.66%
PREMIUM_ECONOMY	974	9.74%
BUSINESS	956	9.56%
FIRST	204	2.04%

Distribución por moneda de pago

Moneda	Transacciones	Porcentaje
USD (Dólar estadounidense)	6,176	61.76%
GTQ (Quetzal guatemalteco)	1,662	16.62%
MXN (Peso mexicano)	1,356	13.56%
EUR (Euro)	806	8.06%

Canales de venta

Canal	Reservas	Porcentaje
AEROPUERTO	2,024	20.24%
WEB	1,995	19.95%
AGENCIA	1,958	19.58%
CALL_CENTER	1,947	19.47%
APP	1,932	19.32%
DESCONOCIDO	144	1.44%

Top 5 aerolíneas por vuelos

Aerolínea	Vuelos
Copa Airlines	888
Southwest	868
Iberia	867

JetBlue	853
Ryanair	850

Top 5 nacionalidades de pasajeros

Código	País	Pasajeros
PA	Panamá	923
US	Estados Unidos	909
MX	México	908
SV	El Salvador	900
ES	España	899

Calidad de Datos — Resumen

Indicador	Valor
Total registros fuente (Dataset_1 + Dataset_2)	20,000
Registros con problemas de calidad corregidos	3,600 (18%)
Registros cargados exitosamente en Hechos_Vuelo	10,000
Registros omitidos por datos críticos faltantes	0
Tablas de dimensión creadas	9
Índices de optimización creados	6